

重庆大学本科学生毕业设计（论文）

基于深度学习的无人机检测识别技术研究



学 生：赵云淞

学 号：20183909

指导教师：蒋卫恒

专 业：电子信息工程

重庆大学微电子与通信工程学院

2022 年 6 月

Graduation Design (Thesis) of Chongqing University

**Research on UAV Detection Technology
Based on Deep Learning**



Undergraduate: Zhao Yunsong

Supervisor: Prof. Jiang Weiheng

Major: Electronic Information Engineering

**School of Microelectronics and Communication
Engineering
Chongqing University
June 2022**

摘 要

随着无人机技术和产业的持续发展,构建一个可靠、高精度的无人机检测和识别系统变得尤其重要。相比较于传统的雷达、视觉和声学无人机检测技术,本文研究一种基于深度学习和时频分析的无人机检测算法。该算法通过挖掘无人机射频通信信号的时频特征,从而实现对无人机种类和无人机飞行模式的探测。本文最初研究的算法采用短时傅里叶变换提取信号特征,和基于 LSTM 的分类网络。测试结果表明无人机类型识别率整体在 98%以上,飞行模型识别率在 95%以上。然而,由于 Parrot Bebop 和 Parrot AR 2.0 来自于同一厂家,射频信号特征相似度高,本文的算法在识别这两类无人机时受干扰较高,准确率仅为 82%。因此,本文研究一种基于 Transformer 的分类网络。其采用小波变换提取信号特征。实验结果表明小波变换与 Transformer 的组合情况下精度最高,达到 94%。但是,该模型时间复杂度较高。最后,根据无人机检测和识别系统的低时延和高精度的性能要求,作者采用小波变换与 LSTM 的组合作为实际系统的组成部分。

关键词: 无人机检测和识别系统, 短时傅里叶变换, 小波变换, 长短期记忆网络

ABSTRACT

With the continuous development of UAV's technology and industry, constructing a reliable and high-precision UAV detection and recognition system is extremely necessary. Compared with the traditional radar, visual and acoustic UAV detection technologies, a novel UAV detection algorithm based on deep learning and time-frequency analysis are researched. This algorithm detects and classifies the types and flight attitudes of UAV through mining the time-frequency characteristics of RF communication signals of UAV. Short-time Fourier Transform extracting the raw signal features, and Classification Network based on LSTM are used in the original model. The experimental results show that the recognition rate of most types of UAVs is more than 98%, and the average classification rate for the flight attitudes of UAVs can reach more than 95%. However, since Parrot Bebop and Parrot AR 2.0 are from the same manufacturer and have high similarity in RF signal characteristics, the precision of aforementioned algorithm is highly interfered to identify these two types of UAV, with an accuracy of 82%. Therefore, a classification network based on Transformer and wavelet transform, a way to extract raw signal features more precisely and comprehensively, are researched. The experimental results show that the combination of wavelet transform and Transformer has the highest accuracy, reaching 94%. However, this model has a high-time complexity. Finally, based on performance requirements of UAV detection and recognition system with low delay and high precision, the author adopts the combination of wavelet transform and LSTM as a part of the actual system.

Key words: UAV's Detection and Recognition System, STFT, Wavelet Transform, LSTM

目 录

摘 要.....	I
ABSTRACT	III
1 绪论.....	1
1.1 研究背景和意义	1
1.2 国内外研究现状	1
1.3 本文主要研究内容	3
1.4 论文组织架构	4
2 信号分析与深度学习基本理论.....	5
2.1 信号分析技术基本理论	5
2.1.1 时域分析	5
2.1.2 频域分析	6
2.2 深度学习基本理论	7
2.2.1 有监督的神经网络	7
2.2.2 无监督的神经网络	11
2.3 本章小结	12
3 无人机检测与识别系统的总体设计	13
3.1 模型框架	13
3.2 数据集	14
3.3 特征提取	15
3.3.1 重采样	15
3.3.2 归一化	15
3.3.3 滤除噪声	15
3.3.4 时频分析	16
3.3.5 时频序列	18
3.4 分类网络	19
3.4.1 基于 LSTM 的分类网络.....	19
3.4.2 基于 Transformer 的分类网络	20
3.5 本章小结	21
4 仿真分析	23
4.1 收敛性分析	23
4.2 精度分析	24

4.3 时间复杂度对比	27
4.4 精度对比	29
4.5 本章小结	30
5 总结与展望	31
5.1 总结	31
5.2 展望	31
致谢	
参考文献	35

1 绪论

1.1 研究背景和意义

由于集成电路行业、远程控制技术、传感器、人工智能等相关技术的发展，无人机的成本、续航里程等多个性能指标也得到了突破式地进展，这也使得无人机已经逐渐从军用、工业界逐渐走入大众视野。与此同时，基于无人机的应用也越来越丰富，如交通监控^[1]、天气观测^[3]、灾害管理^[4]、农业喷洒化学品检测^[5]、基础设施检测^[6]、火灾探测和保护^[7]等。然而，日渐丰富的无人机的应用也带来了许多技术和安全上的问题，如间谍活动、非法或危险货物的转移、堵塞电力和电话线、袭击等^[8]。此外，由于无人机集群技术的出现，空域中的无人机数量越来越多。这些数量庞大的无人机必然将给机场区域、军事秘密区域和客流密集区域带来巨大的安全风险隐患。因此，对于有效减低无人机所造成的风险，发展无人机的探测和识别技术变得十分重要。典型的无人机探测系统如图 1.1 所示。

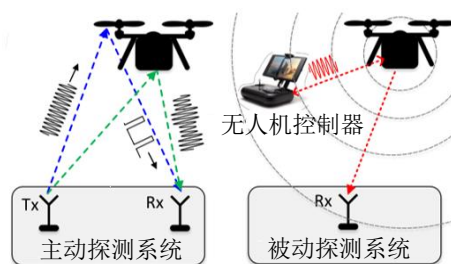


图 1.1 无人机探测系统图

传统的无人机探测技术，如雷达探测、无线电信号探测^[8]、光电识别跟踪、声音检测等^[10]，都存在着不同的优势和缺点，如表 1.1 所示。多特征融合的无人机检测和识别方法已经成为主流趋势^[11]。并且，目前的无人机类型主要以“低慢小”为主，它们是一种小型无人机或飞机，具有飞行高度低、飞行速度慢、不易被侦察发现等特点^[12]。图 1.2 为传统的“低慢小”无人机。单一、传统的无人机探测和识别系统已经不能满足高精度、低时延的性能要求。因此，建立一个高精度、实用性强的无人机探测和识别系统的需求应运而生。本课题聚焦于如何在大数据时代背景下建立该系统的研究。

1.2 国内外研究现状

在大数据发展迅速的时代背景下，许多国内外研究人员关注到机器学习、神经

网络等人工智能手段对建立一个更加可靠的无人机探测和识别系统的帮助。大数据的出现使得系统的精度和误警率大幅度改善；人工智能算法使得系统具有了自学习的功能，随着新的数据输入到系统中，该系统的模型也随之发生改变^[13]。然而，对于高性能的系统的需求，选择合适的数据集、特征和检测算法成为了研究人员们面临的难题之一。马旗等人以 YOLOV3 为架构基础，利用双通道的方法检测和识别低空高速无人机^[14]；徐俊辉等人利用信号相关性、时频分析等手段建立旋翼无人机探测和识别系统^[15]；蒋平、谢跃雷设计基于飞控信号频谱特征的无人机识别和检测系统^[16]。文献[17]中表示，射频信号具有易捕捉、可以有力表征不同无人机的特点。并且无人机的射频信号在其他 Wi-Fi、蓝牙等信号噪声干扰时，对于分类网络来说，仍能表现出良好的性能。因此，许多研究人员选取射频信号作为表征无人机的原始特性^[18]。



图 1.2 无人机示意图

针对信号的特征提取阶段，现存主流的方法主要分为时域、频域的方法，如图 1.3 所示^[19]。此外，针对于时域和频域来说，研究人员们分别总结出恰当的特征指标^[20]。

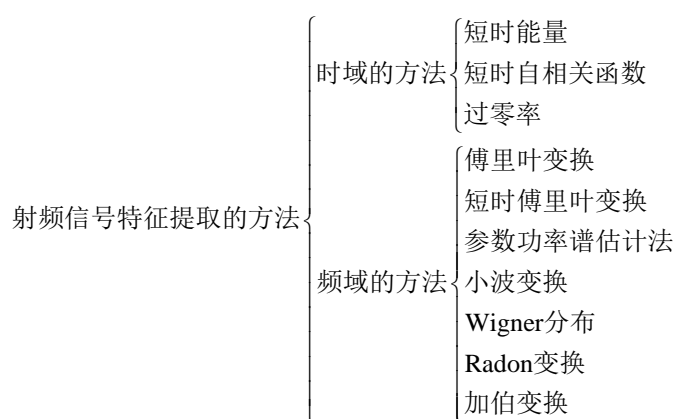


图 1.3 射频信号特征提取方法

在探究如何将人工智能算法与建立检测和识别无人机的系统有效地结合的问题

题中，许多研究人员们提出开创性的想法。MHD Saria Allahham 等人提出了一种基于深度学习的一维多通道卷积神经网络方法，用于无人机检测、类型识别和状态识别，它可以以更紧凑的形式更好地表示数据集中的新特性^[21]，从而更加准确、高效地检测无人机。庞存锁等人利用旋翼无人机的分数阶域特征检测和识别该类无人机，旋翼无人机检测准确率达到 87% 以上^[22]。Wang 等人提出了一种基于长短时记忆的无人机系统异常检测方法，其将预测值与不确定区间进行比较，实现异常检测^[23]。睢丙东等人基于 YOLOv3 和 KCF 算法实现对无人机的跟踪和检测^[24]。Medaiyese 等人提出了一种基于预训练卷积神经网络算法 SqueezeNet 的无人机识别分类算法^[25]。Lai 等人提出了基于深度学习的距离估计^[26]。该方法将深度神经网络和卷积神经网络应用于运动目标距离估计，并对它们的运动目标距离估计性能进行了测试。另外，为了解决动态飞行特征引起的原始特征偏差问题，Zhao 等人提出了一种基于动态特征增强的小型无人机 m-DS 识别算法^[27]。该算法采用动态属性引导对 DAGA 算法进行增强，扩展特征域进行模型训练，以实现复杂环境下高效的多类识别模型。INemer 等采用基于层次概念的集成学习对无人机的类型和飞行状态进行分类^[28]。该方法由四个分类器组成，它们以分层的方式工作，对不同的无人机信息进行检测和分类。

表 1.1 主要无人机探测技术对比

探测手段	作用距离	优点	缺点	成本
雷达探测	10km	探测距离远	受噪声影响大	高
无线电探测	6km	精准定位	受环境影响大	中
光电识别探测	5km	隐蔽性高	稳定性低	中
声音探测	200m	稳定性高	探测距离近	低

1.3 本文主要研究内容

本文主要研究如何利用开源的射频信号数据库，建立一个高精度、有效地无人机检测和识别系统。本课题主要针对软件和算法方面的研究，不涉及传感器、探测器等硬件方面的研究。本文将信号分析处理技术与深度学习算法相结合，构建出达到目的性能指标的系统。具体研究内容如下：

- ① 学习和掌握信号时频分析的原理，并利用 MATLAB 编程实现；
- ② 学习和掌握常见人工智能分类网络和算法的基本原理，以及相互之间的区别、优缺点。并利用 MATLAB 编程实现；
- ③ 针对开源的射频信号数据库，选择适合的特征提取方法，并搭建与之匹配的分类网络。并利用 MATLAB 实现；

- ④ 对输出的结果进行仿真分析和数值分析。

1.4 论文组织架构

本论文的研究重点是基于射频信号（Radio-Frequency Signal, RF）和深度学习（Deep Learning, DL）的无人机检测识别技术。本文主要分为4个部分，组织结构如下：

第一章为绪论，阐述建立无人机探测和识别系统的背景和研究意义。第一章介绍国内外研究人员对于无人机检测技术的研究现状，并对本文的研究内容进行概括。

第二章介绍本文所需的基础理论，在这一部讲述本文涉及到的信号分析与深度学习的基本理论。信号分析技术对应本文模型的特征提取阶段；深度学习对应本文模型的分类网络构建阶段。此外，第二章对信号分析技术和深度学习技术展开说明，比较不同模型和方法的优缺点。以此为本文的选型分析提供基础理论。

第三章为总体设计，详细阐述本文模型的整体构建和设计。首先，第三章介绍本文所提的射频信号和深度学习的无人机检测识别技术的模型框架；之后，介绍本文数据集的来源于 Mohammad F. Al-Sa'd 等人开发的开源无人机射频信号数据集^[29]；随后，详细阐述本文的特征提取的方法，对采用的时频分析方法 STFT 和小波变换的原因和实现手段进行详细介绍，并对该阶段所采用的降噪、过一化等手段进行整体概述；接下来，介绍本文提出的基于 LSTM 和 Transformer 的神经分类网络，并分析该网络的作用。最后，对本文所提模型的性能进行了仿真分析，并用混淆矩阵等手段对模型进行定量分析。

第四章是本篇文章的工作总结以及对未来工作的展望。

2 信号分析与深度学习基本理论

本章对该课题所需涉及的信号分析以及深度学习基本理论进行简要介绍。信号分析应用于该课题所构建的模型中特征提取的部分；深度学习技术应用于分类网络构建的部分。

2.1 信号分析技术基本理论

2.1.1 时域分析

① **过零率**：“过零率”是信号的频率特性，表征某一信号过零点的次数。在观测信号的“过零率”特征前，需对信号进行中心化处理。表达式如下：

$$Z_n = \frac{1}{2} \sum_{m=0}^{N-1} |\text{sgn}[x_n(m)] - \text{sgn}[x_n(m-1)]| \quad (2.1)$$

其中， n 为对应的帧数， N 为一帧的长度， sgn 函数表达式如下， sgn 函数图像如图 2.1 所示。

$$\text{sgn}[x] = \begin{cases} 1, & (x \geq 0) \\ -1, & (x < 0) \end{cases} \quad (2.2)$$




图 2.1 sgn 函数图像

② **短时能量**：“短时能量”是信号能量特性的一种量化指标，表征的是信号在时域的能量特性。表达式如下。

$$E_n = \sum_{m=0}^{N-1} x_n^2(m) \quad (2.3)$$

其中， E_n 表示信号 $x_n(m)$ 的短时能量， n 为对应的帧数， N 为一帧的长度。

③ **短时平均幅度差**：“短时平均幅度差”是信号在单个周期内振幅的变换的量化指标。非周期信号的短时平均幅度差是相对于参考值的幅值差。其都是两个极值

之间差异的幅度函数。

$$r_n(k) = \sum_0^{N-1} |x(n) - x(n+k)|, k = 0, 1, \dots, N-1 \quad (2.4)$$

其中， x 是加窗截断后的信号， n 为对应的帧数， N 为一帧的长度。

④ **自相关**：自相关是信号的时域特性，展现信号内部的相关度。在特定情况下，自相关特性可以表现出信号的能量。表达式如下。

$$R_n(k) = \sum_{m=0}^{N-1-K} [x(n+m)w(m)][x(n+m+k)w(k+m)] \quad (2.5)$$

其中， n 为对应的帧数， N 为一帧的长度， $w(m)$ 为被截断的窗函数。

2.1.2 频域分析

① **傅里叶变换**：“傅里叶变换”作为信号频域变换的基础，将信号用周期性的傅里叶级数近似表达，从而将信号从时域空间映射到频域空间。公式 2.6 所示。

$$F(\omega) = F[f(t)] = \int_{-\infty}^{+\infty} f(t)e^{-i\omega t} dt \quad (2.6)$$

傅里叶变换作为基础的信号频域分析工具，缺点如下：

- 1) 傅里叶变换不能在时域中描述信号的局部特征；
- 2) 傅里叶变换无法精确展现非平稳信号的频域特征。

② **短时傅里叶变换 (Short Time Fourier Transform, STFT)**：“短时傅里叶变换”是基于傅里叶变换发展而来。STFT 的本质就是在信号序列上加窗，在每个窗内进行傅里叶变换。通过上述操作，STFT 可以近似刻画信号的每个时刻所对应的频率。表达式如下。

$$STFT(t, \theta) = \int_{-\infty}^{\infty} [x(\tau) * w^*(\tau - t)] e^{-j\theta\tau} d\tau \quad (2.7)$$

STFT 改善了傅里叶变换不能刻画信号时域的局部特性的缺点，但仍然有着先天的劣势，即 STFT 给信号所加的窗的大小。

- 1) 当所选择的窗太小时，窗内信号序列过于短，频率分辨率低；
- 2) 当所选择的窗太宽时，窗内信号序列过于长，时间分辨率低。

③ **小波变换 (Wavelet Transform, WT)**：“小波变换”是由 STFT 变换而来，将 STFT 给信号所加的矩形窗变为可以随着信号发生改变的窗。由于小波变换有两个变量：尺度、平移量，因此其可以有效地提取信号的二维特征—时间、频率。表达式如下^[30]。

$$CWT_x(a, b) = \frac{1}{\sqrt{a}} \int_{-\infty}^{+\infty} x(t) \varphi\left(\frac{t-b}{a}\right) dt \quad (2.8)$$

小波变换 (WT) 同样是基于傅里叶变换发展而来。相比于傅里叶变换, WT 具有如下的优势^[31]:

- 1) 在信号的高频部分, WT 具有较高的时间分辨率和较低的频率分辨率;
- 2) 在信号的低频部分, WT 具有较高的频率分辨率和较低的时间分辨率。

④ **S 变换**: S 变换不同于前三种变换, 其基函数不是单一的函数, 是由正态函数和简谐振动函数乘积得来。并使用高斯窗函数。这使得其可以自适应调节分辨率且逆变换无损可逆。表达式如下^[30]。

$$S_x(t, f) = \int_{-\infty}^{+\infty} x(t) w^*(\tau - t) e^{-j2\pi f \tau} d\tau \quad (2.9)$$

其中, $w(t) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{t^2}{2\sigma^2}}$, $\sigma(f) = \frac{1}{f}$ 需满足条件: $\int_{-\infty}^{+\infty} w(\tau - t, f) d\tau = 1$ 。

⑤ **维格纳-维勒分布 (Wigner-Ville Distribution, WVD)**: WVD 作为非线性变换, 与傅里叶变换为代表的线性变换有着性质上的不同。对于非稳态的随机信号, 相对于线性变换, WVD 有着非常明显的优势。表达式如下^[30]。

$$WVD_x(t, f) = \int_{-\infty}^{+\infty} x(t + \tau/2) x^*(t - \tau/2) e^{-j2\pi f \tau} d\tau \quad (2.10)$$

从上式可以发现, WVD 变换中的线性积分运算可能会导致大量交叉项的出现, 这一现象会影响频域分析的性能。

⑥ **平滑伪维格纳-维勒分布 (Smoothed Pseudo Wigner-Ville Distribution, SPWVD)**: SPWVD 解决 WVD 易受交叉项影响的缺点, 在 WVD 的积分项中加入时域窗函数 $h(\tau)$ 和频域窗函数 $g(u)$ 。表达式如下^[30]。

$$SPWVD_x(t, f) = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} g(u) h(\tau) x(t - u + \tau/2) x^*(t - u - \tau/2) e^{-j2\pi f \tau} du d\tau \quad (2.11)$$

⑦ **Choi-Williams 分布 (Choi-Williams Distribution, CWD)**: CWD 相对于 SPWVD 的优势在于, 在尽可能保证不损失信号项的能量的情况下, 保持了 SPWVD 的优势—对交叉项进行抑制。造成这一优势的主要原因在于其内部参数 σ 。表达式如下^[30]:

$$C_x(t, f) = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} \phi(\eta, \tau) e^{j2\pi f(s-t)} x(s + \tau/2) x^*(s - \tau/2) ds d\tau d\eta \quad (2.12)$$

其中, CWD 的核函数为高斯函数, 参数 σ 可以控制削弱交叉项: σ 较大, 核函数越平坦, 当 $\sigma \rightarrow \infty$ 等效于 WVD, σ 值越小交叉项衰减程度就越大。

2.2 深度学习基本理论

2.2.1 有监督的神经网络

目前为止, 大部分的神经网络和深度学习模型都是基于有监督的神经网络构

建出来。在监督学习中，模型的学习对象带有标签，这使得模型具有更高的精度。因此，有监督的神经网络具有许多的应用场景，可以满足不同情况下的需求。

① **卷积神经网络（Convolutional Neural Networks, CNN）**：一个卷积神经网络通常由 6 个部分组成，结构图如图 2.2 所示。




图 2.2 CNN 结构图

如图 2.2 所示，在输入层和输出层中，进行数据的输入和输出；卷积计算层主要操作为：局部关联、窗口滑动。其主要作用在于提取数据中的潜在意义，然后通过激励函数映射到结果空间，RELU 函数与 Sigmoid 函数为常见的激活函数，函数示意图如图 2.3 所示；池化层的作用在于降低数据中的噪声。常见的池化层，以及其优缺点与正向传播算法如表 2.1 所示^[32]。




图 2.3 激活函数示意图

表 2.1 常见池化层的优缺点与正向传播算法

池化方法	优点	缺点	正向传播算法
最大池化	保留边缘特征	丢弃细节特征	领域内取最大
平均池化	保留背景	数据差异性小	领域平均
随即池化	泛化能力强	随机性高	按照概率选择
全局平均池化	减少网络参数	丢弃局部特征	全局平均

② **循环神经网络 (Recurrent Neural Network, RNN)**: RNN 与 CNN 不同, RNN 的输出由输入和当前状态共同决定。RNN 作为一个重复性神经网络模块, 利用时间信息进行确定性地建模。RNN 延展结构如图 2.4 所示。




图 2.4 RNN 延展结构图

RNN 在 t 时刻接收到输入 X_t 之后, 隐藏层为 S_t , 输出值是 H_t 。在这过程中, H_t 的值不仅仅取决于 X_t , 还取决于 X_{t-1} 。表达式如下。

$$\begin{aligned} H_t &= g(V \cdot S_t) \\ S_t &= f(U \cdot X_t + W \cdot S_{t-1}) \end{aligned} \quad (2.13)$$

RNN 的出现使得数据内部的相关性成为数据挖掘中有力的特征, 为神经网络的发展提供开创性的意见。但梯度爆炸和梯度消失问题使得 RNN 不具有长期储存记忆的功能, 这成为限制 RNN 广泛应用的阻碍。

1) 梯度爆炸: 当 $W > 1$ 时, 梯度随着时间和距离增加逐渐增强, 使得较远时刻的状态对当前状态影响过大;

2) 梯度消失: 当 $W < 1$ 时, 梯度随着时间和距离增加逐渐变弱, 使得较远时刻的状态对当前状态影响过下。这两种情况都是不符合实际情况的。

③ **长短期记忆 (Long short-term memory, LSTM)**: LSTM 解决 RNN 上述的问题, 可以有效地捕捉到较长时间段内的有效信息, LSTM 单元结构如图 2.5 所示。

如图 2.5 所示, LSTM 网络内部共有三个状态:

1) 忘记阶段: 该阶段类似于带通滤波器, 滤除无用冗余信息, 保留有用信息并输入到下一个模块;

2) 选择记忆阶段: 该阶段主要是对输入 q^t 进行选择保留, 增加有用信息权重, 减低无用信息权重;

3) 输出阶段: 该阶段决定哪些信息会被作为当前状态输出。

LSTM 虽然在一定程度上解决传统 RNN 的长期依赖问题, 但是当数据时间跨

域较大时，LSTM 无法展现出理想的性能。并且，由于 t 时刻的计算高度依赖于 $t-1$ 时刻的运算结果，LSTM 与传统的 RNN 的并行计算能力受到极大限制。




图 2.5 LSTM 单元结构图

④ **Transformer:** Transformer 抛弃传统的 CNN 和 RNN 网络结构，构建编码器-解码器（encoder-decoder）的模型结构。Transformer 的网络结构由自注意力机制（self-Attention）和前馈网络（Feed Forward Neural Network）组成。这一网络结构使得 Transformer 从全局角度审视数据，与 CNN 从局部提取数据特征有着本质的不同。简化结构图如图 2.6 所示。




图 2.6 Transformer 简化结构图示

Transformer 中的核心是 Self-Attention 过程。在 Self-Attention 过程中有三个特征向量 *Query*、*Key*、*Value*。其计算过程如下^[33]：

- 1) 将输入数据转换为嵌入向量（Embedding Vector）；
- 2) 根据嵌入向量得到 *Query*，*Key*，*Value* 三个向量；
- 3) 计算每个向量的得分（*Score*）， $Score = Query * Key$ ；
- 4) 对 *Score* 进行归一化处理；
- 5) 映射到结果空间，点乘 *Value*，得到评分 *V*；
- 6) 输出结果 $Z = \sum V$ 。

⑤ **离散霍普菲尔德神经网络 (Discrete Hopfield Neural Networks, DHNN):** DHNN 的工作模式分为异步和同步两种。在异步工作模式下, 网络的一个时刻更新一个神经元, 公式 2.14 所示; 在同步工作模式下, 网络在一个时刻更新所有的神元的状态, 见公式 2.15。

$$\mathbf{x}_i^{(k+1)} = \begin{cases} \text{sgn}(\sum_{j=1}^n w_{ij} \mathbf{x}_j^k - T_i), i = c \\ \mathbf{x}_i^k, i \neq c \end{cases} \quad (2.14)$$

$$\mathbf{x}_i^{(k+1)} = \text{sgn}(\sum_{j=1}^n w_{ij} \mathbf{x}_j^k, T_i), i = 1, 2, \dots, n \quad (2.15)$$

其中, $w_{i,j}$ 代表网络中上一层第 i 个神经元到下一层第 j 个的传递权重; k 代表网络的时刻。sgn 函数为激活函数。

2.2.2 无监督的神经网络

① **自编码器 (Autoencoder):** 自编码器由三层前馈神经网络单元构成。相对于前馈算法, 由于自编码器特殊的隐藏层, 自编码器没有梯度消失等问题。具体应用有非线性降维、高维数据可视化、特征提取等。Autoencoder 在不同情况下的功能是不同的。自编码器的结构示意图如图 2.7 所示。




图 2.7 自编码器结构示意图

② **Hebb 学习:** Hebb 学习的权向量 \mathbf{w} 不是基于输出的误差来调整, 是由输入和输出的乘积构成。其本质是无监督的学习模式。 t 时刻的权重向量修正值表达式如公式 2.16 所示。

$$\Delta \mathbf{w}(t) = \eta \mathbf{y}(t) \mathbf{x}(t) \quad (2.16)$$

如上式可见, Hebb 学习中, 输入权重与神经元的输入输出紧密相关。当某一神经元的某一维的输入和输出同相时, 输入的权重将会增大; 当某一神经元的某一维的输入和输出反相时, 输入的权重将会减小。

2.3 本章小结

本章主要介绍该课题所需应用技术的理论背景。本章分为两个大方面进行介绍：信号分析技术的理论背景、深度学习的理论背景。信号分析技术主要应用与下文所提出模型的特征提取阶段；深度学习主要应用于模型的分类网络构建方面。其中，信号分析技术本章又分为时域分析和频域分析两个方面进行介绍；深度学习技术本章分为有监督的神经网络和无监督的神经网络两个角度进行介绍。

3 无人机检测与识别系统的总体设计

本章介绍本课题基于射频信号与深度学习的无人机检测识别系统的整体涉及。本章从数据集的获取、特征提取、分类网络构建等方面详细阐述该系统模型的构成。此外，本章将利用数值分析与仿真分析的技术手段分析系统模型的性能指标。

3.1 模型框架

本文模型的整体框架如图 3.1 所示。输入的数据为 Mohammad F. Al-Sa'd 等人发布的开源无人机射频信号数据^[24]。本文模型通过时频分析工具将输入的原始时域信号数据映射到时频域空间，得到信号的时频特性。并利用 MATLAB 软件对信号进行降噪和归一化处理。由于输出的时频图之间差异性不明显，难以得到理想的分类效果。本文模型将输出的时频图按照图像的列读取数据，得到时间-频率序列。之后，本文采用基于深度学习的分类网络来分类时间-频率序列。最后，本文通过数值分析和仿真等手段分析模型的泛化能力与其他性能指标。并且，本文给出混淆矩阵等工具量化模型的性能。

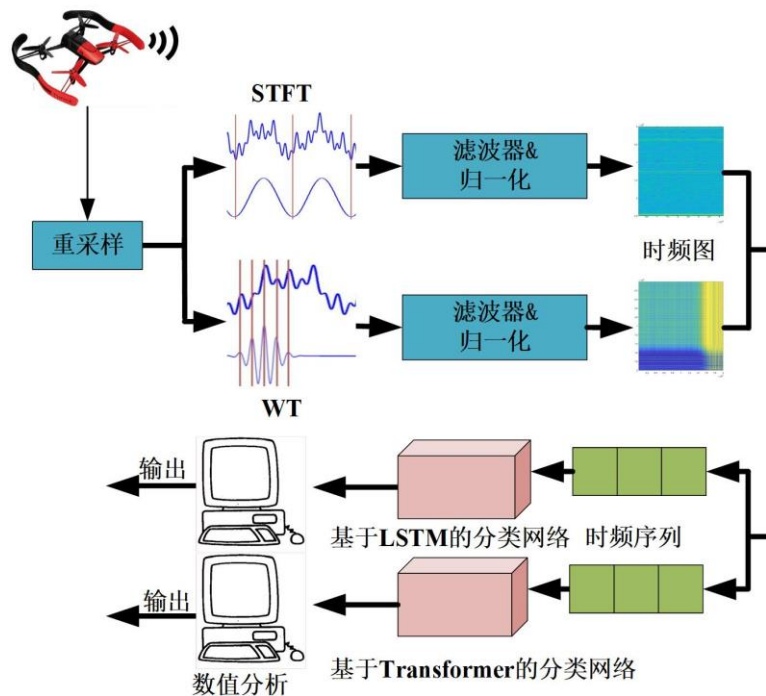


图 3.1 模型整体框架图

在实际实现过程中，本文最初采用 STFT 来挖掘射频信号的时频特征、基于

LSTM 的分类网络来对时频序列进行分类。但由于上述算法针对 Parrot Bebop 和 Parrot AR 2.0 的分类效果不理想通过对比，本文研究基于小波变换的时频分析方法和基于 Transformer 的分类网络。上述模型相较于 Mohammad F. Al-Sa'd 等人在文献[24]中提出的 CNN 分类模型都有较大改进。

3.2 数据集

本课题的原始数据来源于 Mohammad F. Al-Sa'd 等人开发的开源无人机射频信号数据集^[24]。Mohammad F. Al-Sa'd 等人利用两个射频接收器截获无人机的射频信号，其中一个射频接收器用来接收无人机的高频信号；另一个用于接收无人机的低频信号，两个接收机的最大瞬时带宽为 40 兆赫兹，具体参数见表 3.1。

表 3.1 射频接收机参数

参数	数值区间
通道数	2
频率步长	<1KHz
颗粒范围	0dB-37.5dB
最大瞬时带宽	40MHz
最大 I/Q 采样率	200MS/s
ADC 采样率	14 比特

开源数据集中包括射频背景噪声和三类无人机的通讯射频信号—Parrot Bebop、Parrot AR 2.0、DJI Phantom 3。Mohammad F. Al-Sa'd 等人将数据集分为三个层级^[24]。第一层级判断是否有无无人机、第二层级判断无人机的种类、第三层级判断无人机的飞行状态。并且，Mohammad F. Al-Sa'd 等人使用二进制标识符（Binary Unique Identifier, BUI）对数据库进行标记。

BUI 是由两个二进制数字连接而成的， $BUI=[msBUI, IsBUI]$ 。msBUI 是 BUI 中最重要的部分，代表实验和无人机类型，即数据集中的第一级和第二级；IsBUI 是 BUI 中最不重要的部分，代表无人机飞行模式，即数据集中的第三级。BUI 的长度 L 是用实验总数 E 、无人机总数 D 和飞行模式总数 F 确定的^[24]，表达式如公式 3.1 所示。

$$L = [\log_2(E)] + [\log_2(D)] + [\log_2(F)] \quad (3.1)$$

3.3 特征提取

3.3.1 重采样

本文所采用的数据集为 Mohammad F. Al-Sa'd 等人在 2019 年发布的开源数据集。该数据集的数据量较为庞大，对计算机硬件要求高，普通的个人电脑难以承担运行该数据集的任务。同样，庞大的数据量也给模型的拟合和训练带来困难，极大增加模型的拟合难度。因此，本文对数据进行重采样，利用 MATLAB 编程实现。在重采样过程，需要满足奈奎斯特采样定理，即不失真地恢复信号，采样频率应该大于等于被采样信号频谱中最高频率的 2 倍，表达式如公式 3.2 所示。

$$f_s \geq 2f_{\max} \quad (3.2)$$

3.3.2 归一化

本课题利用 MATLAB 工具对 STFT 变换后的频域数据进行归一化处理。在将数据输入进分类网络前，需要对数据进行归一化处理，将数据的值压缩到 0-1 之间。归一化消除奇异样本对模型训练的影响，进一步消除噪声对模型训练的影响，表达式如下。

$$\frac{x - \min(x)}{\max(x) - \min(x)} \quad (3.3)$$

3.3.3 滤除噪声

本课题利用 MATLAB 实现对信号的滤波，图 3.2 为进行归一化和滤除噪声后的信号。




图 3.2 预处理后信号

本文所采用的滤波器表达式如公式 3.4 所示。滤除噪声可以使得经过 STFT 变

换后的数据去除无用信息，保留有用，即信噪比增大。在训练分类网络的过程中，使模型更易收敛，得到性能指标理想的分类模型。本文数据集中的射频信号的带宽为 40 兆赫兹，且无人机射频信号噪声主要为高频噪声。由此，本文选择低通滤波器滤波。

$$X_2(t, f) = \int_{f-\frac{M}{2}}^{f+\frac{M}{2}} \int_{t-\frac{T}{2}}^{t+\frac{T}{2}} |X(t_0, f_0)| dt_0 df_0 \quad (3.4)$$

其中， $X(t, f)$ 为原始射频信号经过 STFT 变换后的时频数据； $X_2(t, f)$ 为 $X(t, f)$ 经过时域降噪后的时频数据。 $X_2(t, f)$ 为 $X(t, f)$ 取模后，经过双重线性积分所得。图 3.2 为进行归一化和滤除噪声后的信号。

3.3.4 时频分析

本文对 Mohammad F. Al-Sa'd 等人^[24]的研究中提供的无人机射频信号开源数据集中的 ADC 数据进行解调。本文的主要目的是对无人机射频信号进行分类，以实现对是否有无人机、无人机的种类、飞行状态等检测。不同无人机的射频信号的差异主要取决于其通信逻辑，包括不同的数据包长度、包间隔、包频率等。因此，为了更加清晰地提取不同无人机信号特征的差异性，本文将时域 ADC 数据 $x(t)$ 转换为频域信号。本文采用短时傅里叶变换（STFT）和小波分析（WT）提取信号的时频特性，关于 STFT 和 WT 的具体介绍详见 2.1.2 节。

① 基于 STFT 的时频分析方法

本文采用的 STFT 表达式见公式 3.5

$$X(t, f) = \int_{t-\frac{T}{2}}^{t+\frac{T}{2}} x(t_0) \cdot e^{j2\pi f t_0} dt_0 \quad (3.5)$$

其中， $x(t)$ 代表时域的射频信号； $X(t, f)$ 代表经过 STFT 变换后的射频信号。

此时， $X(t, f)$ 为一个二维函数，可视化后为一个图像，即时频图（Time-Frequency Graph, TFG），图示如图 3.2 所示。该数学原理也揭示相较于传统的傅里叶变换，STFT 可以提供某一时刻具体的频率值的原因。具体实现过程如下。

1) 令时间 t 从 0 开始以恒定的差值递增，分别求出各个 t 值下信号的短时傅里叶变换（短时傅里叶变换得到的结果是一个向量），然后按 t 值的大小将所求得的短时傅里叶变换的结果进行排列，得到一个矩阵。且，相邻 t 值间的差值可以小于窗函数的长度，两个相邻的信号段有一定重叠。利用 MATLAB 中的 spectrogram 函数编程实现；

2) 对上文中所得矩阵中的数据进行变换，将的取矩阵中数据的取值范围变为 0 到 1 之间。此时，矩阵可以作为灰度图像显示，得到时频图的锥形。该操作过程

与传统的归一化不同，在确定一个上限值后，将大于等于该上限值的矩阵中的数据变换为 1，小于该上限值的矩阵中的数据除以上限值。这样可以有效的避免因矩阵中某几个数据过大导致归一化后大部分数据的差值过小。利用 MATLAB 中的 `mat2gray` 函数编程实现：

3) 将得到的灰度图像数据转化成彩色图像数据，得到最终的时频图。
具体变换过程见图 3.3。

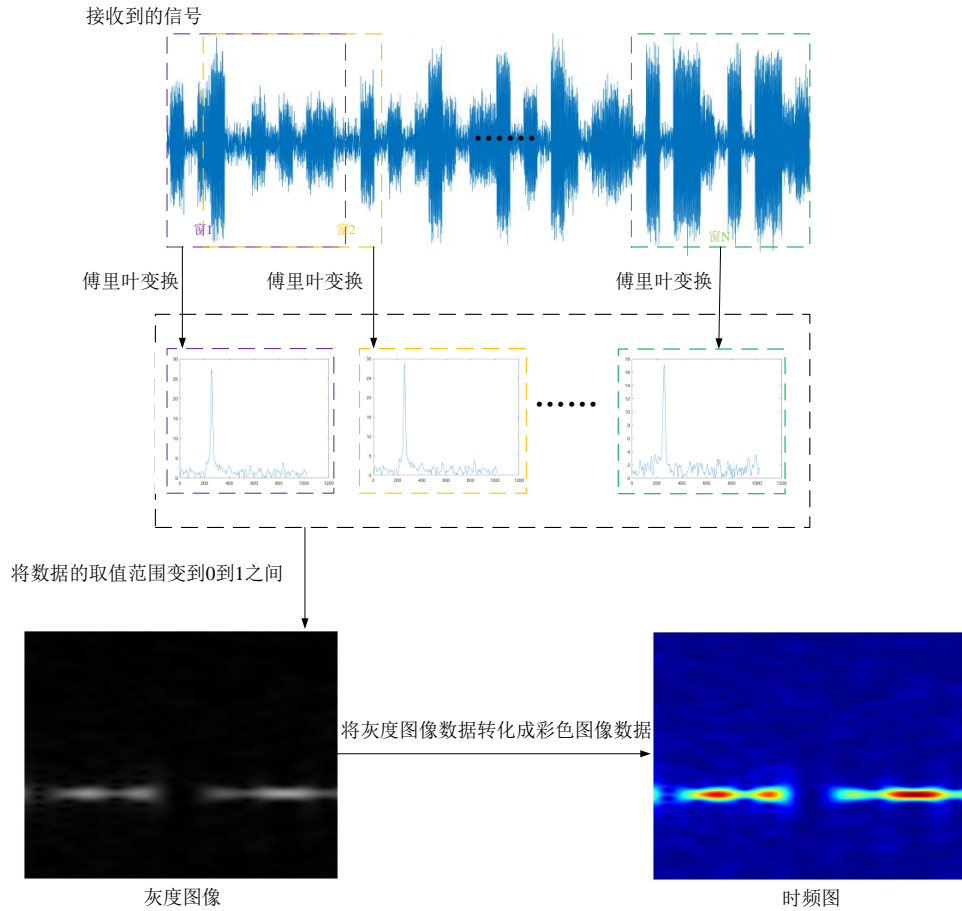


图 3.3 STFT 示意图

② 基于 WT 的时频分析方法

本文采用的 WT 表达式见公式 3.6：

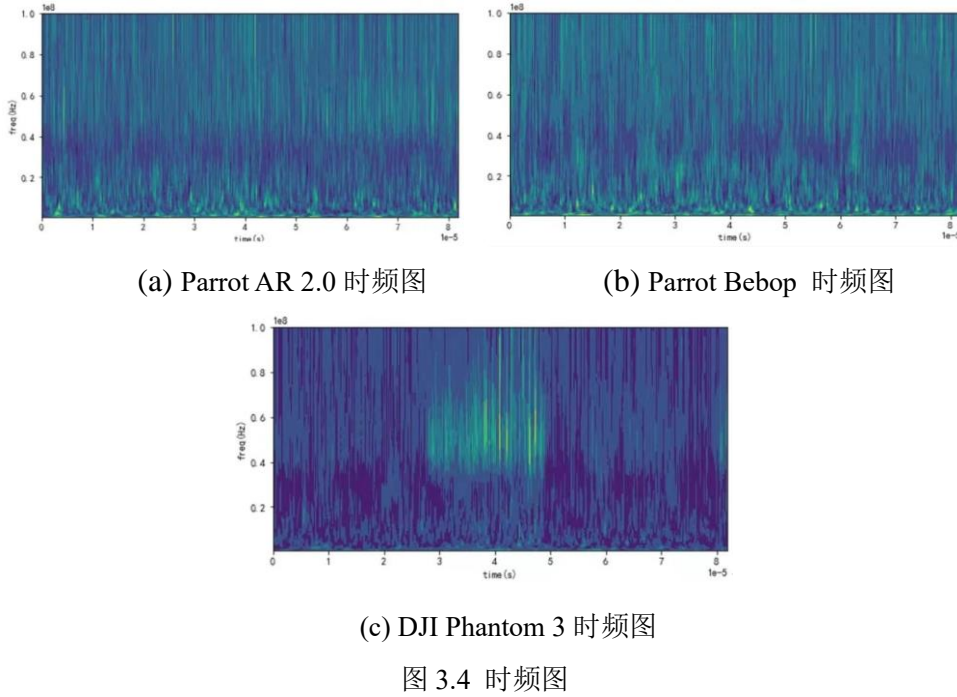
$$t(u, v) = \sum_{x=0}^{N-1} \sum_{y=0}^{N-1} f(x, y) s(x, y, u, v) \quad (3.6)$$

其中，公式 3.3 为二维离散信号的变换公式， $t(u, v)$ 为输出的时频图， $f(x, y)$ 为二维信号， $s(x, y, u, v)$ 为变换函数。

本文具体实现小波函数操作过程的步骤如下：

- 1) 打开 MATLAB 软件，输入原始信号数据；
- 2) 选择合适的小波基函数，由于输入的原始信号数据为离散小波函数，我们选择 `dwt2` 函数，实现二维离散小波变换，MATLAB 代码为 `dwt2 (X,'haar')`；
- 3) 对输出的时频矩阵进行可视化表达变成时频图。

本文采用两种方法对原始射频信号进行时频变换，WT 相对于 STFT 具有一定的优势，但其时间复杂度相对较高。图 3.3 展示三种无人机的射频信号经过时频变换后的时频图，图像的横轴代表时间；纵轴代表频率；图像的颜色代表能量。由图 3.4，可以发现时频图作为神经网络的输入存在的明显问题：时频图之间的差异性不明显，尤其 Parrot Bebop、Parrot AR 2.0 这两种无人机的时频图相似度较高。由此，本文提出相应解决方案一将时频图按列读取成为时频序列。



3.3.5 时频序列

如 3.3.1 节所介绍，将时频图作为二维数据输入进神经网络中存在一定的挑战。时频图之间的差异性不明显，且二维数据的输入会使得神经网络的复杂度提高。经实验说明，当神经网络输入为时频图，参数的调整等较为复杂，且输出结果不理想。因此，本文对经 STFT 变换后所得到的时频图按列进行读取，得到时频序列（Time-Frequency Sequence），表达式如下：

$$Y = [X_2(t_0, f_0), X_2(t_0, f_1), \dots, X_2(t_0, f_n), X_2(t_1, f_0), X_2(t_1, f_1), \dots, X_2(t_k, f_n)] \quad (3.7)$$

3.4 分类网络

本文的目的是利用无人机的通信规律来区分其类型和飞行状态，将无人机的 ADC 的时域数据通过时频分析工具转换为时频数据后，利用分类网络实现无人机的时频数据进行分类，进一步达到检测无人机及其飞行状态的目的。输入的特征数据以及所需的理想输出结果都影响分类网络的选取和构建。如，当输入的数据为二维图像时，可以选择 AlexNet 等分类网络；当输入的数据为序列时，可以选择 LSTM、RNN 等分类网络。

3.4.1 基于 LSTM 的分类网络

本课题中输入网络里的数据为时间-频率序列，因此本文优先选择 RNN、LSTM、Transformer 等分类网络。本文研究的基于 LSTM 的分类网络结构如图 3.5 所示。

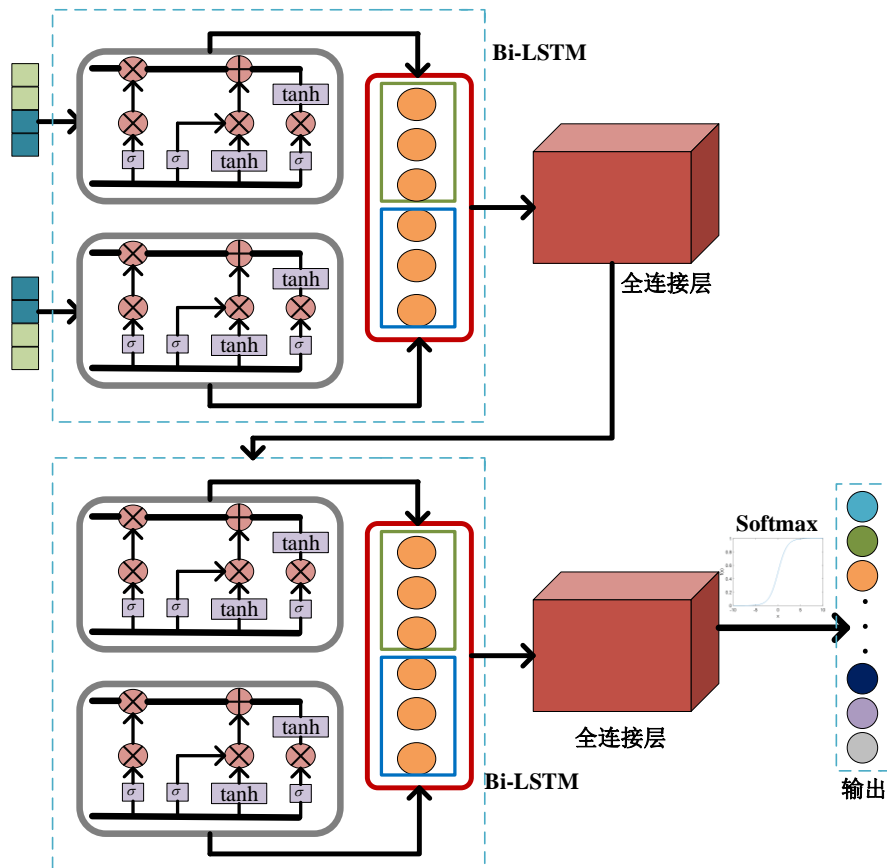


图 3.5 基于 LSTM 的分类网络结构

如图 3.5 所示，该网络共有 7 层。一层序列输入层（Sequence Input Layer, SIL）、两层双向长短期记忆层（Bi-LSTM 层）、两层全连接层（Fully Connected Layer, FCL）、一层采用 Softmax 作为激活函数的激励层（Activating Layer, AL）、一层分类输出层（Classification Output Layer, COL）。

在序列输入层，神经网络输入为时频域信号序列，序列长度为 $k * n$ ；Bi-LSTM 层是由 LSTM 基本单元组成，Bi-LSTM 的主要作用是解决从后到前的编码问题其由前向 LSTM 与后向 LSTM 组合而成；在全连接层中，全连接层的每个节点都连接到上层的所有节点，用来合成先前提取的特征。在分类输出层，网络输出的最后的判断类别，即给出无人机的类别或飞行状态。神经网络各层的具体参数如表 3.2 所示。Softmax 层是多分类激活层，表达式见公式 3.8 所示。

$$\text{Soft max}(z_i) = \frac{e^{z_i}}{\sum_{c=1}^C e^{z_c}} \quad (3.8)$$

由上式可以发现，Softmax 作为激活函数存在很大的问题。引入指数型函数导致输出结果的敏感度过高，输入数据微小变化会引起输出结果的强烈波动。

表 3.2 基于 LSTM 分类网络结构

序号	层的类型	参数
1	序列输入层	$k * n$
2	双向长短期记忆层	128
3	全连接层	16
4	双向长短期记忆层	32
5	全连接层	4/9
6	激励层	\
7	分类输出层	\

3.4.2 基于 Transformer 的分类网络

由于基于 LSTM 的分类网络存在着分类精度上限较低的问题，即当数据规模达到一定程度时，模型的分类效果仍然不变。因此，本文同样研究基于 Transformer 的分类网络，Transformer 详细介绍见 2.2.1 节。

Transformer 在处理较长时间序列时，拥有一定的优势。本文直接利用 MATLAB 实现 Transformer 模型。在实际运算中，Transformer 模型的运算时间明显高于 LSTM，这也说明 LSTM 的轻量化优势。但在分类精度方面，Transformer 的精度相比 LSTM 算法有一定的提升。这也证明，当数据量达到一定规模时，Transformer 的模型表现高于 LSTM。因此，本文研究的基于 Transformer 的分类网络精度在理论上应该高于基于 LSTM 的分类网络。基于 Transformer 的分类网络见图 3.6 所示。

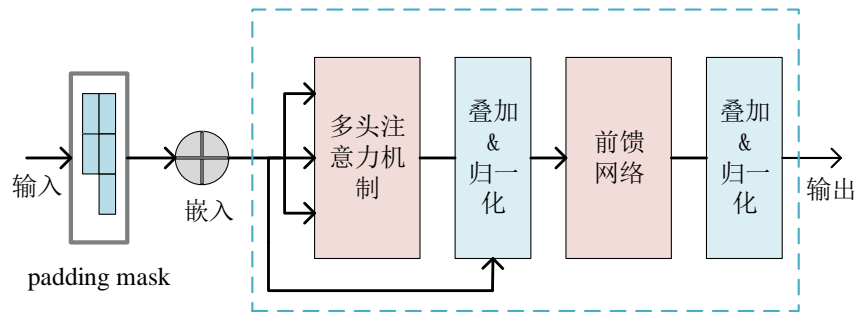


图 3.6 基于 Transformer 的网络结构

本文基于 Transformer 的分类网络具体实现过程如下：

- ① 本文主要利用 Python 来实现基于 Transformer 的分类网络结构；
- ② Transformer 作为 Seq2Seq2 架构的模型，本文主要将 Transformer 分为编码器和解码器两个部分来实现；
- ③ 获取输入信号的每一段信号的表示特征 Z ，将其输入到编码器模块中（Encoder Block）中；
- ④ 将编码器模块中输出的编码信息矩阵输入到解码器模块（Decoder Block）中。解码器模块会根据之前状态翻译当前状态，并通过掩盖（Mask）操作遮盖住之后的信息。

3.5 本章小结

本章研究基于深度学习网络和射频信号时频分析的无人机探测和识别系统。该系统既可以检测无人机的类别还可以检测无人机的飞行状态。具体地，本章首先阐述模型整体框架和数据集来源，使读者对模型有系统性地认识和了解；随后，本章主要通过特征提取和分类网络的构建两个方面对模型进行整体性介绍。在特征提取阶段，本文主要采用时频分析的方法对模型进行特征提取。在利用时频分析工具对信号进行时频分析前，本文对原始滤波信号进行滤波、重采样以及归一化，使得特征在输入到分类网络时，分类效果更加理想且增强模型的可行性。然而，在本章中遇到困难一经过 STFT 变换得到的二维时频图之间的差异性不明显。因此，本文将二维的时频图变为一维的时频序列，再将其输入到分类网络中。根据输入的时频序列特征，本文采用基于 LSTM 的深度学习神经网络，该网络共有 7 层。针对上述算法区分 Parrot Bebop、Parrot AR 2.0 效果不明显的特点，本文额外采用小波变换作为时频变换工具、基于 Transformer 的深度学习神经网络作为分类网络。

4 仿真分析

4.1 收敛性分析

收敛性分析是深度学习网络中常见的仿真分析手段。一方面，通过收敛性分析，可以清晰判断所建立的算法模型是否具有收敛性，即在一定时间内，算法会找到全局最优解；另一方面，收敛性分析可以量化地给出收敛速度等指标。本节以基于 LSTM 与 STFT 的无人机检测和识别算法为例进行展示。图 4.1 是“识别无人机类别”任务模型的收敛性分析。




图 4.1 “识别无人机类型”的收敛性分析图

由上图可见，训练数据部分不会误判无人机的类型，且随着迭代次数的增加，分类精度提高，损失减小。当迭代次数增加到 100 时，分类精度和损失趋于稳定，模型泛化能力强。当迭代次数为 200 时，模型精度接近 100%，损失接近 0%，说明，迭代次数 200 时，本文所提出的基于 LSTM 的分类网络算法找到全局最优解。

表中的损失函数指的是用来度量模型的预测值和真实值差异的函数。当损失函数随着模型迭代次数的增加逐渐降低，说明该模型的预测值逐渐接近于真实值，模型收敛性良好，可以准确输出分类结果。本文模型选用的损失函数是交叉熵函数，表达式如公式 4.1 所示。在模型迭代过程中，损失函数的作用是帮助模型反向传播更新参数，以来降低真实值和预测值之间的差异，从而模型的偏差逐渐变小，预测值向着真实值方向收敛。

$$L = \frac{1}{N} \sum_i L_i = -\frac{1}{N} \sum_i \sum_{c=1}^M y_{ic} \log(p_{ic}) \quad (4.1)$$

接下来,继续对本文所提出的基于 LSTM 和 STFT 的无人机检测和识别系统,在“识别 9 种无人机的不同飞行模式”任务下进行测试。这可以帮助系统更好地确定无人机的飞行意图,以确定下一步的操作,如攻击、忽视或警告。训练结果的收敛性如图 4.2 所示。




图 4.2 “识别无人机飞行模式”的收敛性分析图

图 4.2 与图 4.1 相同,当迭代次数达到 100 次时,算法的分类精度和损失趋于稳定。当迭代次数趋近 200 次时,分类精度接近 100%,损失值小于 0.5。这表明本文提出的基于 LSTM 的神经网络算法收敛速度快,在具体应用中是可行的,无论是检测无人机的类别还是无人机的飞行状态。这也说明该算法具有实际应用价值。

本节通过对本文提出的基于 LSTM 的神经网络算法进行收敛性分析,对算法的收敛速度、精度与损失情况、收敛程度等性能指标有清晰、直观、量化的认知。并通过收敛性分析,进一步检测本文所建立的基于射频信号和深度学习的无人机探测识别系统的可行性以及实用价值。

4.2 精度分析

精度分析是评价一个分类网络性能的必要一环。本节通过混淆矩阵精准、可视化、量化地分析本文所提出的无人机检测和识别系统的精度。本节以基于 LSTM 和

STFT 的无人机检测和识别系统为例。

混淆矩阵是展示分类器的分类结果准确度的矩阵，主要有 4 个指标，如表 4.1 所示。

表 4.1 混淆矩阵指标

序号	参数指标	参数意义
1	真阳性	正类预测为正类
2	假阳性	正类预测为负类
3	假阴性	负类预测为正类
4	真阴性	负类预测为负类

在混淆矩阵中，列数据相加是分类后的类别数、矩阵行数据相加是真实值类别数、其中主要采用量化精度的方法为准确率、精确率和召回率。准确率：对于给定的测试集，分类器正确分类的样本数与总样本数之比，表达式为公式 4.2 所示；精确率：对于给定的测试集，模型预测为正类别有多少为真正的正样本，表达式为公式 4.3 所示；召回率：对于给定的测试集，样本中的正样本有多少被预测正确，表达式如公式 4.4 所示。

$$accuracy = \frac{TP + TN}{\text{总样本数}} \quad (4.2)$$

$$precision = \frac{TP}{TP + FP} \quad (4.3)$$

$$recall = \frac{TP}{TP + FN} \quad (4.4)$$

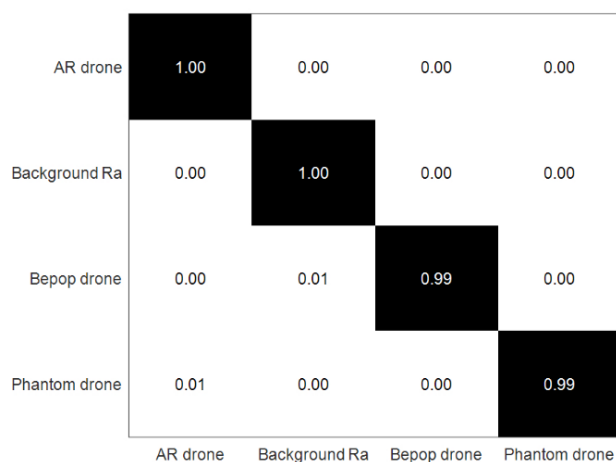


图 4.3 “识别无人机类型”的混淆矩阵

首先是无人机的类型识别仿真实验，数据分类的混淆矩阵如图 4.3 所示。本文研究的基于 LSTM 的神经网络可以有效地从训练数据集中提取出信号的特征，训练数据部分不会误判无人机的类型，即该模型的偏差较小。

如图 4.3 所示，该算法具有良好的分类性能。Parrot AR 2.0 无人机、背景噪声、DJI Phantom 3 无人机的识别率理想。实验结果进一步说明本文所提出的算法的可行性与鲁棒性。为了进一步验证该算法的可靠性，本文将原始射频信号数据随机分为训练集和测试集，其中 80% 为训练集，20% 为测试集。反复训练模型，得到该模型预测分类结果精度的平均值，其混淆矩阵如图 4.4 所示。

AR drone	0.98	0.01	0.01	0.00
Background Ra	0.00	1.00	0.00	0.00
Bepop drone	0.17	0.00	0.82	0.00
Phantom drone	0.00	0.00	0.00	1.00
	AR drone	Background Ra	Bepop drone	Phantom drone

图 4.4 “识别无人机类型”的平均混淆矩阵

从图 4.4 可见，本文研究的无人机检测和识别系统具有良好的性能。三种标签—AR drone、Background Ra、DJI Phantom3 的识别率均在 98% 以上。但 Bebop drone 的识别率却仅有 82%，有 17% 的概率被误判为 AR drone。本文通过查阅文献以及原始开源数据库，发现 Bebop drone 和 AR drone 来源于同一家生产公司。因此，两款无人机的通信射频信号的特征有更大的概率具有相似的特征，对本文所提出的算法造成一定的干扰。若需大幅度提高网络对 Bebop drone 和 AR drone 的分类精度，本文研究的基于 LSTM 的神经网络仍需提高其挖掘深层次特征的能力，增大网络层数，但会带来更高的时间复杂度，以及硬件负担。因此，考虑到时间复杂度以及对硬件的需求上，本文所提的算法在精度方面仍然具有优势。综上，证明本文的算法能够有效地识别无人机的类型。

接下来，本节对本文提出的基于 LSTM 的神经网络在确定无人机的飞行模式的情况下进行精度分析，仍然采用混淆矩阵量化分析。为了验证本文所提算法

的可行性，本文依旧将原始数据集随机分为训练集和测试集，其中 80% 为训练集。对模型重复训练多次，得到平均精度，如图 4.5 所示。

0	1.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00
16	0.04	0.95	0.01	0.00	0.00	0.00	0.00	0.00	0.00
18	0.00	0.01	0.99	0.00	0.00	0.00	0.00	0.00	0.00
19	0.00	0.00	0.00	1.00	0.00	0.00	0.00	0.00	0.00
20	0.00	0.00	0.00	0.02	0.98	0.00	0.00	0.00	0.00
21	0.00	0.00	0.00	0.00	0.00	1.00	0.00	0.00	0.00
22	0.00	0.00	0.00	0.00	0.00	0.01	0.99	0.00	0.00
23	0.00	0.00	0.00	0.00	0.00	0.00	0.00	1.00	0.00
24	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	1.00
	0	16	18	19	20	21	22	23	24

图 4.5 “识别无人机飞行状态”的平均混淆矩阵

由图 4.5 可见，本文所研究的基于 LSTM 的深度学习神经网络算法在检测无人机的飞行状态时，表现低于该算法检测无人机的类别时。但是，该算法相对于原始的 CNN 网络有了明显精度上的提高。在图 4.5 中，该算法在检测无人机的飞行状态的任务中平均分类精度达到 0.99，方差小于 0.001。由此，也可以进一步说明，本文所研究的基于 LSTM 的神经网络分类算法对于 9 种无人机飞行状态分类的可行性。

此外，毫无疑问，随着无人机技术和应用的逐渐普及，无人机的检测和识别方法也必然会逐步发展。无人机类型的识别和无人机的飞行状态的检测将逐渐多样化。科研人员们也并将提出许多新的方法。这些方法不仅可以使使用传统的特征进行检测，如射频信号和图像监控，还可以结合多角度、更全面的特征对无人机的类别和飞行状态进行检测和识别。

4.3 时间复杂度对比

本文主要利用两种时频分析方法对信号进出特征提取——短时傅里叶变换、小波分析；并构建了两种分类网络——基于 LSTM 的分类网络、基于 Transformer

的分类网络。在实际应用过程中，及时性、低时延是理想的无人机探测系统需要具备的性能。因此，本文对上述两种时频分析方法和分类网络进行时间复杂度的对比和分析。

短时傅里叶变换本质是以滑动窗口的形式，做快速傅里叶变换（Fast Fourier Transform, FFT），而 FFT 的时间复杂度为 $O(N * \log N)$ 。所以，短时傅里叶变换的时间复杂度约为 FFT 的时间复杂度 $O(N * \log N)$ 。

小波变换同样可以看作在不同窗口内的 FFT，因此小波变换的时间复杂与 FFT 相当为 $O(N * \log N)$ 。

LSTM 一共需要四个模块，输入门、遗忘门、候选态、输出门。当 LSTM 网络中，输出层和隐藏层的大小相同时。在一般情况下，LSTM 的时间复杂度为 $4(nm + n + n^2)$ ，其中 n 为 LSTM 中隐藏层的大小， m 为 LSTM 中输入层的大小。在本文中，输入层和隐藏层的大小大约相等，其量级约为 $8n^2$ 。

Transformer 的时间复杂度取决于每层的情况，下表为 Transformer 每层的时间复杂度。

表 4.2 Transformer 每层时间复杂度对比

序号	网络层	时间复杂度
1	Self-Attention	$O(n * d^2)$
2	Recurrent	$O(n * d^2)$
3	Convolution	$O(k * n * d^2)$

其中， d 为表征向量的维度、 n 为输入序列的长度、 k 为卷积核的大小。根据本文设计的 Transformer 情况，本文研究的 Transformer 的量级为 $10n^2$ 。

本文所进行的实验是基于 CPU 电脑进行的，CPU 的型号为 i7-8650U。如表 4.3 所示，不同方法组合的运算所需时间。表 4.3 数据为本文 10 次实验所得平均值。

表 4.3 算法运行时间对比

序号	时频分析	分类网络	运行时间
1	STFT	LSTM	286.3 秒
2	STFT	Transformer	330 秒
3	WT	LSTM	290.2 秒
4	WT	Transformer	334.2 秒

4.4 精度对比

精确度是评判本文设计的无人机探测和识别系统的可行性的重要参考指标之一。因此，对比和分析不同方法组合的精度是十分有意义的，有助于本文选择合适的时频分析方法和深度学习网络。

根据上文所述，本文研究的基于 STFT 和 LSTM 的无人机检测和识别系统的精确度大部分情况下都是理想的。但当该系统识别和检测 Parrot Bebop 和 Parrot AR 2.0 这两种无人机时，基于 LSTM 和 STFT 的无人机的检测和识别系统的精确度只有 82%。为此，本文提出基于 Transformer 的分类网络，和基于小波变换的特征提取方法。Transformer 相对于 LSTM，对特征处理更加全面，分类效果更好。小波变换相对于 STFT，对信号的时频特征提取更加准确，对于后续分类网络的分类准确度地提升有着显著作用。如表 4.4 所示，本文各个方法组合的算法，在识别和检测 Parrot Bebop 和 Parrot AR 2.0 这两种无人机时的精度对比。迭代次数为 200。离散傅里叶变换(Discrete Fourier Transform, DFT)和卷积神经网络(Convolutional Neural Networks, CNN)的算法组合的精度来自于 Mohammad F. Al-Sa'd 等人^[24]。精度的可视化柱状图如图 4.6 所示。

表 4.4 算法精度对比

序号	时频分析	分类网络	精度
1	STFT	LSTM	82%
2	STFT	Transformer	92%
3	WT	LSTM	86%
4	WT	Transformer	94%
5	DFT	CNN	71.45%

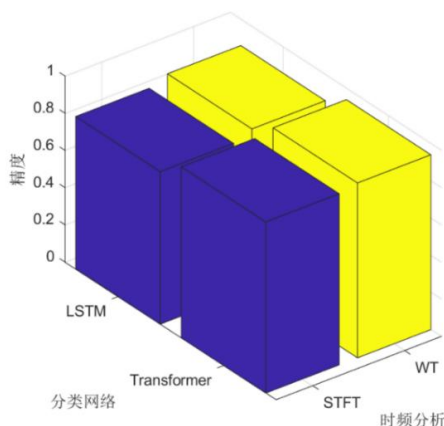


图 4.6 算法精度柱状图

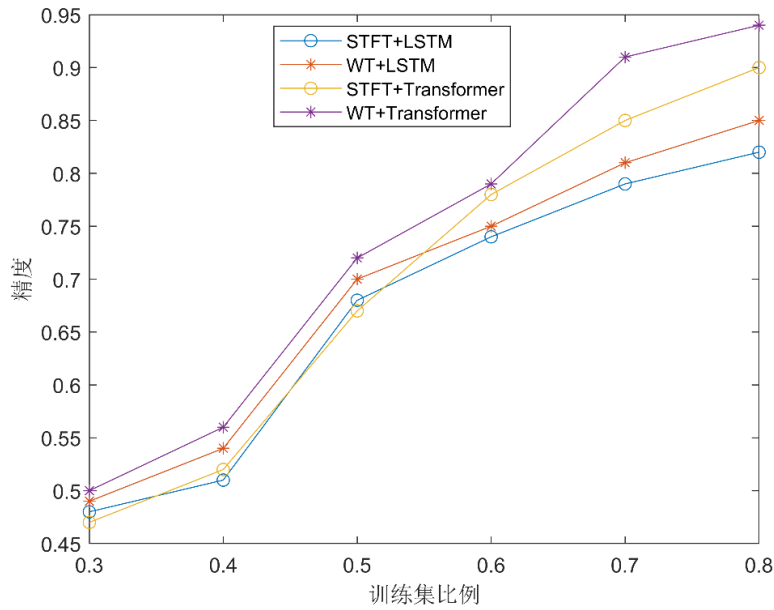


图 4.7 训练集比例随精度变换示意图

本文为更进一步刻画不同算法在无人机检测和识别系统中的可行性，对不同算法的精度随着训练集比例的变化趋势进行仿真刻画。在实际无人机检测和识别系统中，无法确保每时每刻系统都具有充足的数据集来训练系统模型。因此，针对不同算法在不同的训练集数据量大小的情况下精度的仿真十分必要。这也确保本文建立的无人机检测和系统的稳定性。如图 4.7 所示，在训练集比例较低时，四种算法的表现几乎是相同的。且四种算法的精度在训练集达到 0.5 时，都有大幅度地提升。在整体的表现上，STFT+Transformer 的模型具有一定的精度优势。

4.5 本章小结

本章对本文所研究的无人机检测与识别系统进行仿真分析。从收敛性分析、精度分析等多个角度可视化、量化展现本文算法的性能优缺点和不同算法之间的性能对比。基于 STFT 和 LSTM 的算法在检测无人机的类别时，精度整体在 0.99 左右。在检测无人机的飞行状态的任务中，该模型平均分类精度达到 0.99，方差小于 0.001。但是，该模型对 Bebop drone 和 AR drone 两者检测精度不理想，这是由于 Bebop drone 和 AR drone 来自于同一家生产厂商，通信的射频信号特征具有较强的相似性。因此，本文提出基于 Transformer 的分类网络，以及采用小波变换来提取射频信号的特征。基于 Transformer 的分类网络的时间复杂度明显高于基于 LSTM 的分类网络。最后根据无人机检测和识别系统的低时延和高精度的性能要求，本文采用小波变化与 LSTM 的组合作为实际系统的组成部分。

5 总结与展望

5.1 总结

针对日益增长的无人机的探测和识别需求,利用无人机的无线通信射频信息,本文提出一种基于射频信号和深度学习的无人机的识别和探测技术,并搭建相应的实验平台,通过仿真分析和数值分析验证了该方案的有效性和可靠性。实验结果表明,本文最初研究的基于 STFT 和 LSTM 的算法在“检测无人机的类别”的任务中,对测试数据中射频信号的平均识别率为 95%,对大多数类型的无人机的识别率均在 98%以上。在“检测无人机的飞行状态”的任务中,本文所提出的算法对无人机的飞行状态的分类精度可以达到 95%以上。但是对 Parrot Bebop 和 Parrot AR 2.0 这两类无人机的精度仅为 82%。因此,本文额外采用小波变换和基于 Transformer 的分类网络。并对不同种算法组合从时间复杂度和精度两个角度进行仿真分析。Transformer 的精度高于 LSTM,但其时间复杂度也明显高于 LSTM。最后,根据本文研究的无人机检测和识别系统稳定性和低时延等性能要求,本文最后选择采用小波变换和 LSTM 作为系统算法。实验结果由混淆矩阵量化、可视化表示。结果表明,本文提出的基于射频信号和深度学习的无人机探测和识别算法能够有效地满足实际场景中无人机检测和识别的需要。本文的主要研究工作如下所示:

第一,通过阅读相关书籍、文献和观看网课,了解和掌握时频分析和深度学习的基础理论知识。并选择合适的开源数据集,基于该数据集训练模型。

第二,对时频分析和深度学习网络中各个模型有一定清晰地了解,从而针对本文的需求和情况选择恰当的模型。

第三,利用 MATLAB 编程实现本文提出的模型假设,并对本文选择的开源数据集的数据进行预处理。

第四,对本文研究的算法进行仿真分析和数值分析,验证本文提出算法的可行性。并选择合适的展现模型性能指标的可视化工具。

第五,完善优化本文所研究的模型参数。

第六,以第一作者的身份撰写发表于国际会议的论文。

5.2 展望

目前,与深度学习和人工智能技术相结合的无人机的探测和识别系统的研究和开放处于起步阶段。一套稳定的、性能指标良好的、低时延的无人机探测和识别系统对于军工乃至工业界都有着极其重要的作用。本文致力于为真正可以用于工业界的无人机探测和识别系统的研发做出贡献。但是,本文的研究还存在一些挑战,

本文提出的算法在检测 Parrot Bebop 和 Parrot AR 2.0 这两款无人机的分类精度还有待提高，因为 Bebop 无人机和 AR 无人机是由同一家生产厂商制造的，因此两种无人机的通信射频信号的特征彼此相似。在接下来的工作中，作者将继续对分类算法进行优化。此外，为了提高 Parrot Bebop 和 Parrot AR 2.0 的分类精度，本文已经有相应的解决方案，选择基于 Transformer 的分类网络，和采用小波变换提取特征。但是该算法的时间复杂度较高。因此，提出一个低时延，高精度的模型是本文之后需要面对的挑战。

致 谢

本课题是在蒋卫恒老师细心指导下进行和实现的。作者从大三上开始跟蒋卫恒老师做科研项目，收获良多。在蒋卫恒老师的细心指导下，作者逐渐对科研有了系统性的认识，了解科研的整体过程，也对机器学习等领域有了入门的理解。蒋老师对科研认真的态度也影响着作者，使作者在本科阶段有机会接触到科研，感受到科研本身的魅力，以及克服困难后的满足感。

同时，回顾整个大学生活，身边许许多多的同学都对作者的成长起到至关重要的影响。从大一的懵懂无知到如今临近毕业的踌躇满志，身边的同学老师不仅影响着我的学业，也给我的生活观念的形成产生帮助。在大一的时候，盲目地在考试中考出高分是当时唯一的目的；后来，逐渐和同学或老师一次次长谈，慢慢发现自己需要找寻努力的目的，进而使自己的努力有了意义。

我很感谢我的父母，支持我的决定。在我焦躁、感到难以坚持的时候给我适当的鼓励。并且，给我的学习和生活尽可能提供条件。他们的鼎力支持使我才可以心无旁骛学习和朝着目标努力。

最后，感谢我的母校——重庆大学。在重庆大学的四年，是我三观逐渐稳定，逐渐成长为具备明辨是非能力的成年人。同样，在重庆大学提供的优质的资源和微电子与通信工程学院老师的高质量的教学下，作者对专业的认知和理解得到质的提升。

由衷地感谢能够抽出时间来参加答辩和评阅论文的各位专家、教授！

参 考 文 献

- [1] CHOW J. Dynamic UAV-based traffic monitoring under uncertainty as a stochastic arc-inventory routing policy [J]. *International Journal of Transportation Science and Technology*, 2016, 5(3): 167–185.
- [2] MOHAMMED, IDRIES A, N. MOHAMED N, et al. UAVs for smart cities: opportunities and challenges [C]// 2014 International Conference on Unmanned Aircraft Systems (ICUAS). IEEE, 2014: 267–273.
- [3] KLEMAS V. Coastal and environmental remote sensing from unmanned aerial vehicles: an overview [J]. *Coastal Research*, 2018, 31(5): 1260–1267.
- [4] ERDELJ M, NATALIZIO E, CHOWDHURY K R, et al. Help from the sky: leveraging UAVs for disaster management [J]. *IEEE Pervasive Computer*, 2017, 16(1): 24–32.
- [5] HUANG Y, THOMSOM S J, HOFFMANN W C, et al. Development and prospect of unmanned aerial vehicle technologies for agricultural production management [J]. *International Journal of Agricultural and Biological Engineering*, 2013, 6(3): 1–10.
- [6] HAM Y, HAN K K, LIN J J, et al. Visual monitoring of civil infrastructure systems via camera-equipped unmanned aerial vehicles. A review of related works [J]. *Visualization Engineering*, 2016, 4 (1): 12-19.
- [7] CRUZ H, ECKERT M, MENESES J, et al. Efficient forest fire detection index for application in unmanned aerial systems [J]. *Sensors*, 2016, 16(6): 893-887.
- [8] GANTI S R, KIM Y. Implementation of detection and tracking mechanism for small UAS [C]// 2016 International Conference on Unmanned Aircraft Systems (ICUAS), 2016: 1254–1260.
- [9] KLARE J, BIALLOWONS O, CERUTTI-MAORI. UAV detection with MIMO radar [C]// 2017 18th International Radar Symposium (IRS), 2017: 1-8.
- [10] DING G, WU Q, ZHANG L, et al. An amateur drone surveillance system based on the cognitive internet of things [J]. *IEEE Communication Magazine*. IEEE, 2018, 56(1): 29–35.
- [11] 谢跃雷, 蒋平, 刘信. 基于图传信号多特征融合的无人机检测与识别方法: 中国, CN111652183A[P]. 2022-03-29.
- [12] 丘恺彬. 基于音频特性的无人机检测与识别研究[D]. 南京: 南京理工大学, 2018.
- [13] 黄湘鹏, 黄晓刚. 一种基于深度学习的无人机识别方法[J]. *雷达与对抗*, 2020, 40(2):6-10.
- [14] 马旗, 朱斌, 程正东. 基于双通道的快速低空无人机检测识别方法[J]. *光学学报*, 2019, 39(12):11-19.
- [15] 徐俊辉, 欧阳缮, 廖可非. 基于相关检测的旋翼无人机检测与识别方法 [J]. *桂林电子科*

- 技大学学报, 2021, 41(6):6-9.
- [16] 蒋平, 谢跃雷. 基于飞控信号频谱特征的无人机检测与识别系统设计 [J]. 电子器件, 2020, 43(4):7-11.
- [17] EZUMA M, EEDEN F, ANJINAPPA C K, et al. Detection and classification of UAVs using RF fingerprints in the presence of Wi-Fi and bluetooth interference [J]. IEEE Open Journal of the Communications Society, 2020, 6(1):60-76.
- [18] 游战清. 无线射频识别技术 (RFID) 理论与应用[M]. 李苏剑. 北京: 电子工业出版社, 2004.
- [19] 孟庆丰. 信号特征提取方法与应用研究[D]. 西安: 西安电子科技大学, 2006.
- [20] 知乎. 常用信号特征提取方法总结[EB/OL]. [2019-11-15]. <https://zhuanlan.zhihu.com/p/91427246>.
- [21] ALLAHHAM M S, KHATTAB T, MOHAMED A. Deep learning for RF-based drone detection and identification: a multi-channel 1-D convolutional neural networks approach [C]// 2020 IEEE International Conference on Informatics, IoT, and Enabling Technologies (ICIOT). IEEE, 2020: 112-117.
- [22] 庞存锁, 侯慧玲, 杨凌. 一种基于分数阶域特征的旋翼类无人机深度学习识别方法: 中国, CN110850386A[P]. 2020-02-28.
- [23] WANG B, WANG Z, LIU L, et al. 2019. Data-driven anomaly detection for UAV sensor data based on deep learning prediction model [C]// 2019 Prognostics and System Health Management Conference (PHM-Paris). IEEE, 2019: 286-290.
- [24] 睢丙东, 苗林星, 于国庆. 基于深度学习的无人机目标检测系统 [J]. 科技风, 2022, 6(1):4-6.
- [25] MEDAIYESE O, EZUMA M, Lauf A P, et al. Wavelet transform analytics for RF-based UAV detection and identification system using machine learning [J]. Pervasive and Mobile Computing, 2021, 82(4): 1015-1023.
- [26] LAI Y C, HUANG Z Y. Detection of a moving UAV based on deep learning-based distance estimation [J]. Remote Sensing, 2020, 12(18): 30-35.
- [27] ZHAO C, LUO G, WANG Y et al. UAV recognition based on micro-doppler dynamic attribute-guided augmentation algorithm [J]. Remote Sensing, 2021, 13(6): 1205-1212.
- [28] NEMER I, SHELTAM T, Ahmad I, et al. RF-based UAV detection and identification using hierarchical learning approach [J]. Sensors, 2021, 21(6): 1947-1959.
- [29] MOHAMMAD F, Al-SA'D, ABDULLA A, et al. RF-based drone detection and identification using deep learning approaches: An initiative towards a large open source drone database [J]. Future Generation Computer Systems, 2019, 100(3): 86-97.

- [30] 刘祥. 基于深度学习的无线通信场景识别研究[D]. 西安: 西安电子科技大学, 2018.
- [31] 童善保. 小波分析及其应用[D]. 上海: 上海交通大学, 1998.
- [32] CSDN. mean-pooling, max-pooling, Stochastic-pooling, global average pooling 的区别简介 [EB/OL]. [2019-08-10]. <https://blog.csdn.net/u013289254/article/details/99080916>.
- [33] ASHISH V, NOAM S, et al. Attention is all you need [C]// NIPS'17: Proceedings of the 31st International Conference on Neural Information Processing Systems. NIPS, 2017: 6000–6010.